

ANÁLISIS DEL COMPORTAMIENTO DE MODELOS ENSAMBLADOS

Por Antonio Jesús García Nieto

[illegible]

TABLA DE CONTENIDO

Control de versiones.....	2
Introducción	4
Planteamiento del estudio	4
Resultados	5
Los resultados de la prueba 1.....	5
Los resultados de la prueba 2.....	6
Los resultados de la prueba 3.....	6
Conclusión del experimento.....	7
Bibliografía.....	7

INTRODUCCIÓN

En este experimento estudiaremos los beneficios de usar modelos ensamblados. Nos basaremos principalmente en (Harangi et al., 2018) donde se propone un ensamblaje formado por AlexNet, VGGNet y GoogLeNet. Los resultados del estudio incentivan el uso de esta estrategia para conseguir precisión extra.

La hipótesis que pretendemos validar en este estudio es:

1. *La mejora de la precisión derivada del ensamblaje de modelos justifica el incremento de parámetros del modelo.*

PLANTEAMIENTO DEL ESTUDIO


En este estudio proponemos un ensamblaje de modelos preentrenados, en concreto de InceptionV3 y RSM_BAJ. Hemos seleccionado InceptionV3 como modelo a ensamblar junto a RSM_BAJ debido a que ambas tienen diferencias en la base de su funcionamiento y a que InceptionV3 aporta una buena relación de profundidad y parámetros.

El funcionamiento de nuestro ensamblaje será sencillo, tanto InceptionV3 como RSM_BAJ reciben la misma entrada, posteriormente el vector salida de cada uno es “unificado”.

Proponemos tres formas de unión:

1. Basada en una capa de promediado.
2. Basada en una capa de maximizado.
3. Basada en una concatenación y procesado mediante dos capas de neuronas densas (128 neuronas) entre las que se intercalan dos capas de Dropout con un coeficiente de 50% y con función de activación PReLU.

A continuación, mostramos un esquema del modelo propuesto.



Se trabajará con imágenes de 128 x 128.

Se seguirá el mismo esquema de entrenamiento que en el experimento 1. Recordemos que el este es:

- El conjunto de entrenamiento = source (60% del total del conjunto de datos),
- El conjunto de reentrenamiento = train (70% del 40% restante del conjunto de datos),
- El conjunto de test = test (21% del 40% restante del conjunto de datos)
- El conjunto de validación = validación (9% del 40% restante del conjunto de datos)

Los hiperparámetros serán los siguiente:

- Ratio de aprendizaje de 0.001 y optimizador Amsgrad.

- Épocas: 30 para entrenamiento.
- Callbacks: Se detiene el entrenamiento si la red consigue peores resultados en 3 ocasiones consecutivas.
- Tamaño de lote: 16.

Los modelos se entrenarán con el conjunto de datos de source y train, se validará con el de validación y se comprobará su resultado el de test.

Para asegurar la robustez de la prueba se entrenará 5 veces cada modelo con cada configuración.

RESULTADOS

Resultados obtenidos por modelos preentrenados sobre los datos de test.

Red	Precisión sobre datos de test
RSM_BAJ	95.5 %
InceptionV3	96.0 %
Media	95.75 %

LOS RESULTADOS PARA ENSAMBLAJE CON MAXIMIZADOR.

Iteración	Pérdida	Precisión
1	0.1890	95.68 %
2	0.1778	96.09 %
3	0.1832	96.12 %
4	0.1786	95.89 %
5	0.1873	95.91 %
Media	0.1831	95.94 %

LOS RESULTADOS PARA ENSAMBLAJE CON MINIMIZADOR.

Iteración	Pérdida	Precisión
1	0.1628	95.68 %
2	0.1631	95.48 %
3	0.1599	95.47 %
4	0.1645	95.65 %
5	0.1608	95.97 %
Media	0.1622	95.65 %

LOS RESULTADO PARA ENSAMBLAJE CON RED NEURONAL

Iteración	Pérdida	Precisión
1	0.2654	95.68 %
2	0.2717	95.48 %
3	0.2862	95.47 %
4	0.2470	95.65 %
5	0.2751	95.97 %
Media	0.2691	94.55 %

CONCLUSIÓN DEL EXPERIMENTO

Los resultados son bastante decepcionantes, con ninguna de las combinaciones hemos conseguido obtener ninguna mejora. Lo único que hemos conseguido ha sido casi triplicar el número de parámetros de la red.

Con estos resultados podemos concluir que el ensamblaje de modelos no es una buena opción para nuestro caso concreto.

BIBLIOGRAFÍA

Harangi, B., Baran, A., & Hajdu, A. (2018). Classification of Skin Lesions Using An Ensemble of Deep Neural Networks. *Proceedings of the Annual International Conference of the IEEE Engineering in Medicine and Biology Society, EMBS, 2018-July*, 2575–2578.
<https://doi.org/10.1109/EMBC.2018.8512800>